

Risultati Sperimentali Modal Dropout su DETR

Le seguenti tabelle riportano i risultati ottenuti sotto diverse configurazioni di *modal dropout* applicate al modello DETR. Durante la fase di valutazione, la modalità di input viene campionata in base a probabilità predefinite $P(\text{IR})$, $P(\text{RGB})$ e $P(\text{Fusion})$.

Addestramento su $D_{\text{RGBa-IRs}}$

Table 1: Risultati del modello addestrato su $D_{\text{RGBa-IRs}}$ con diverse configurazioni di modal dropout.

Testato su	$P(\text{IR})$	$P(\text{RGB})$	$P(\text{Fusion})$	mAP@50
D_{IRo}	100	0	0	0.138
D_{IRo}	90	0	10	0.132
D_{IRo}	50	50	0	0.163
D_{IRo}	37.5	37.5	25	0.132
D_{IRo}	25	25	50	0.159
D_{IRo}	12.5	12.5	75	0.000
D_{IRo}	20	20	60	0.173
$D_{\text{RGBa-IRs}}$	100	0	0	0.379
$D_{\text{RGBa-IRs}}$	90	0	10	0.300
$D_{\text{RGBa-IRs}}$	50	50	0	0.388
$D_{\text{RGBa-IRs}}$	37.5	37.5	25	0.302
$D_{\text{RGBa-IRs}}$	25	25	50	0.377
$D_{\text{RGBa-IRs}}$	12.5	12.5	75	0.000
$D_{\text{RGBa-IRs}}$	20	20	60	0.417

Addestramento su $D_{\text{RGB-IR}}$

Table 2: Risultati del modello addestrato su $D_{\text{RGB-IR}}$ con diverse configurazioni di modal dropout.

Testato su	$P(\text{IR})$	$P(\text{RGB})$	$P(\text{Fusion})$	mAP@50
D_{IRo}	100	0	0	0.224
D_{IRo}	90	0	10	0.261
D_{IRo}	50	50	0	0.227
D_{IRo}	37.5	37.5	25	0.306
D_{IRo}	25	25	50	0.247
D_{IRo}	12.5	12.5	75	0.196
D_{IRo}	20	20	60	0.200
$D_{\text{RGB-IR}}$	100	0	0	0.224
$D_{\text{RGB-IR}}$	90	0	10	0.252
$D_{\text{RGB-IR}}$	50	50	0	0.219
$D_{\text{RGB-IR}}$	37.5	37.5	25	0.280
$D_{\text{RGB-IR}}$	25	25	50	0.233
$D_{\text{RGB-IR}}$	12.5	12.5	75	0.205
$D_{\text{RGB-IR}}$	20	20	60	0.220

Addestramento su D

Table 3: Risultati del modello addestrato su D con diverse configurazioni di modal dropout.

Testato su	$P(\text{IR})$	$P(\text{RGB})$	$P(\text{Fusion})$	mAP@50
D_{IRo}	100	0	0	0.270
D_{IRo}	90	0	10	0.320
D_{IRo}	50	50	0	0.275
D_{IRo}	37.5	37.5	25	0.293
D_{IRo}	25	25	50	0.270
D_{IRo}	12.5	12.5	75	0.158
D_{IRo}	20	20	60	0.256
D	100	0	0	0.322
D	90	0	10	0.361
D	50	50	0	0.331
D	37.5	37.5	25	0.333
D	25	25	50	0.325
D	12.5	12.5	75	0.286
D	20	20	60	0.323

Table 4: Confronto diretto tra i risultati originali e i migliori risultati ottenuti con Modal Dropout. Le righe sono raggruppate per set di addestramento e test per evidenziare l’impatto della nuova metodologia.

Trainato su	Testato su	$P(\text{IR})$	$P(\text{RGB})$	$P(\text{Fusion})$	mAP@50
D	D	0	0	100	0.372
	D	90	0	10	0.361
	D_{IRo}	0	0	100	0.233
	D_{IRo}	90	0	10	0.320
$D_{\text{RGBa-IRs}}$	D_{IRo}	0	0	100	0.000
	D_{IRo}	20	20	60	0.173
$D_{\text{RGB-IR}}$	D_{IRo}	0	0	100	0.000
	D_{IRo}	37.5	37.5	25	0.306

Evoluzione con RT-DETR (Real-Time DETR)

In questa fase della ricerca, l'obiettivo è stato adattare la logica multimodale su un'architettura **RT-DETR**, ottimizzata per l'inferenza real-time. Sono state testate due strategie principali per gestire la natura multi-scala del modello e la risoluzione ridotta dei target.

RT-DETR con Additive Feature Fusion

Questa architettura utilizza una **doppia backbone** (ResNet-50vd) per elaborare separatamente le modalità RGB e IR. Le *feature maps* multi-scala estratte ($P3, P4, P5$) vengono fuse tramite **somma elemento per elemento** (Additive Fusion) e successivamente processate dall'*Hybrid Encoder* (AIFI e CCFM).

Questa scelta presenta due vantaggi chiave:

1. preserva l'allineamento spaziale tra le modalità, mantenendo la compatibilità con il meccanismo di *Deformable Attention* del decoder;
2. non introduce parametri addizionali, evitando instabilità durante il *fine-tuning* del modello pre-addestrato su ImageNet.

Il modello è stato addestrato per 10 e 25 epoche utilizzando una strategia di *modal dropout* (20% IR-only, 20% RGB-only, 60% fusion - rivelatasi la migliore durante i test sul modello DETR) per migliorare la robustezza delle modalità singole.

Table 5: Risultati RT-DETR (Fusion) trainato per 25 epoche su immagine integrale al variare della soglia di confidenza.

Testato su	Threshold	mAP@50 (RT-DETR)	mAP@50 (DETR)
$D_{\text{RGBa-IRs}}$	0.01	0.321	
$D_{\text{RGBa-IRs}}$	0.05	0.287	0.417
$D_{\text{RGBa-IRs}}$	0.10	0.246	
D_{IRo}	0.01	0.262	0.173
D_{VISo}	0.01	0.264	-

Table 6: Risultati RT-DETR (Fusion) trainato per 10 epoche su immagine integrale al variare della soglia di confidenza.

Testato su	Threshold	mAP@50 (RT-DETR)	mAP@50 (DETR)
$D_{\text{RGBa-IRs}}$	0.01	0.357	
$D_{\text{RGBa-IRs}}$	0.05	0.357	0.417
$D_{\text{RGBa-IRs}}$	0.10	0.356	
D_{IRo}	0.01	0.252	0.173
D_{VISo}	0.01	0.246	-

Da queste tabelle notiamo come il training per 10 epoche abbia dato risultati migliori sul dataset fusion ma peggiori sulle singole modalità (RGB/IR). Un aspetto interessante è che in questo caso anche la confidence del modello sembra essere maggiore visto che non c'è quasi alcun peggioramento di prestazioni tra il test con il threshold più basso (0.01) ed il più alto (0.1). Inoltre, rispetto a DETR questo nuovo approccio peggiora le prestazioni sul dataset fusion (0.417 vs 0.357) ma migliora notevolmente le prestazioni sulle singole modalità ($\text{IR} \approx 0.25$ vs ≈ 0.17).

RT-DETR con Strategia di Tiling (SAHI-style)

Per ovviare alla dimensione ridotta dei soggetti, è stato testato un approccio basato su **tiling**: l'immagine 640×640 viene divisa in quadranti 320×320 , raddoppiando la scala relativa degli oggetti. Durante il test, le predizioni sui singoli tile vengono rimappate e aggregate tramite NMS globale.

Durante l'**addestramento**, durato anche in questo caso 10 e 25 epoche, ogni immagine viene ritagliata in modo casuale su uno dei 4 quadranti, mentre durante il **test** tutti i quadranti vengono processati e aggregati tramite NMS globale (soglia IoU 0.5).

Table 7: Confronto della robustezza multimodale: RT-DETR Integrale vs RT-DETR con Tiling.

Test Dataset	Modello Integrale (mAP@50)	Modello Tiling (25 ep.) (mAP@50)	Modello Tiling (10 ep.) (mAP@50)
$D_{\text{RGBa-IRs}}$	0.321	0.302	0.151
D_{IRo}	0.262	0.133	0.105
D_{VISo}	0.264	0.082	0.050

*I risultati del modello Tiling si riferiscono all'inferenza con aggregazione dei quadranti.

Tutti i valori sono riportati con soglia di confidenza 0.01 per evidenziare il potenziale di localizzazione.

RT-DETR con Framework CMX (SOTA Fusion)

È stata infine testata l'integrazione del framework **CMX** (Zhang et al. 2023), che introduce due moduli avanzati: il *Cross-Modal Feature Rectification Module* (CM-FRM) per calibrare i sensori e il *Feature Fusion Module* (FFM) basato su *Cross-Attention*. L'obiettivo era verificare se una fusione adattiva potesse gestire meglio i disallineamenti spaziali del dataset.

Il modello è stato addestrato per 25 epoche. I risultati evidenziano una netta degradazione delle prestazioni rispetto alla somma additiva.

Table 8: Risultati RT-DETR con integrazione CMX (25 epoche).

Testato su	Threshold	mAP@50 (CMX)	mAP@50 (Base)
$D_{\text{RGBa-IRs}}$	0.01	0.032	0.321
$D_{\text{RGBa-IRs}}$	0.10	0.000	0.246
D_{IRo}	0.01	0.081	0.262
D_{VISo}	0.01	0.018	0.264

Questi risultati evidenziano come l'elevata complessità dei moduli CMX (molteplici parametri aggiuntivi in MLP e Attention) introduca un'eccessiva inerzia nel processo di ottimizzazione su un dataset di dimensioni ridotte come il WiSARD. Si osserva un fenomeno di **interferenza distruttiva**: la modalità *Fusion* (0.032) risulta notevolmente inferiore alla modalità *IR-only* (0.082), indicando che il modello non è riuscito a isolare il segnale termico dal rumore visivo. Inoltre, la confidenza del modello è rimasta estremamente bassa, portando a prestazioni nulle con soglia 0.1.

Il Tentativo Ibrido: FAM + CMX + Positional Encoding

Dall'analisi dei fallimenti del modello CMX puro, sono emerse tre criticità principali strutturali legate allo specifico dominio SAR (Search And Rescue):

1. **Disallineamento e Parallasse:** Il modulo di rettifica (CM-FRM) di CMX assume che le feature map siano "pixel-perfect". In presenza di disallineamento, usare il valore infrarosso

per calibrare il pixel visivo sottostante significa mescolare il target con il rumore di fondo, causando una grave interferenza distruttiva.

2. **Perdita di Contesto Spaziale nel FFM:** Il modulo di fusione basato su *Cross-Attention* srotola i token temporaneamente privandoli della cognizione 2D. Senza le posizioni relative, si genera *Ghosting* (l'RGB preleva informazioni termiche da parti casuali ma semanticamente affini o "calde" dell'immagine).
3. **Collo di bottiglia su P3:** A causa della complessità quadratica $O(N^2)$ dell'attenzione, al livello P3 (quello a più alta risoluzione, vitale per trovare bersagli minuscoli) è necessario applicare un fallback lineare (bypass). Fondendo mappe disallineate con una semplice concatenazione lineare si distruggono irrimediabilmente i piccoli target.

Per superare e risolvere teoricamente queste defezioni è stata progettata un'Innovativa **Architettura Ibrida** che incapsula i vantaggi di entrambi gli approcci esplorati. La pipeline *Triple-Step* elaborava le feature nel seguente ordine: $[RGB, IR] \rightarrow FAM \rightarrow CM - FRM \rightarrow FFM$.

In pratica, prima si utilizzavano le Deformable Convolutions del FAM per allineare (warpare) l'IR ed eliminare la parallasse; poi si procedeva con la calibrazione incrociata (ora corretta spazialmente); infine, le feature venivano fuse nel modulo FFM a cui però è stato iniettato un **2D Sine Positional Encoding** customizzato per prevenire il ghosting dell'attenzione.

Il modello è stato addestrato e di seguito sono riportati i risultati finali:

Table 9: Risultati RT-DETR Architettura Ibrida (FAM + CMX + Pos. Encoding).

Testato su	Threshold	mAP@50 (CMX Ibrido)	mAP@50 (CMX Puro)
$D_{RGBa-IRs}$	0.01	0.1447	0.032
$D_{RGBa-IRs}$	0.10	0.0878	0.000
D_{IRo}	0.01	0.0944	0.081
D_{IRo}	0.10	0.0543	0.000
D_{VISo}	0.01	0.1023	0.018
D_{VISo}	0.10	0.0607	0.000

I risultati dimostrano che le intuizioni teoriche erano corrette: l'aggiunta dell'allineamento spaziale e posizionale ha risollevato l'architettura dal collasso totale, riportando le prestazioni multimodali da uno 0.032 a un 0.1447 (e rendendo la rete finalmente in grado di fare previsioni fiduciose anche a iterazione stretta $Thr = 0.10$, dove il CMX originale falliva totalmente con 0.000). Tuttavia, confrontando i valori con la semplice *Additive Fusion* o con la nostra variante regolarizzata SSJ (0.438 mAP), è palese che la mole di parametri e la pesantezza strutturale del blocco CMX generano comunque *overfitting* e inerzia estrattiva su dataset molto piccoli come il WiSARD. Questo esperimento certifica matematicamente che, su task RGBT limitati basati su droni, operazioni di allineamento euristiche e leggere surclassano pesanti framework multimodali attentivi standard.

1 Evoluzione con Deformable DETR: Dalla Fusione Spaziale alla Channel Concatenation

Successivamente la ricerca si è spostata sull’architettura **Deformable DETR**. L’obiettivo era sfruttare il meccanismo di attenzione sparsa (Deformable Attention) per gestire meglio le feature multi-scala, cercando un compromesso tra la complessità computazionale del CMX e la semplicità della somma additiva.

In questa fase sono stati esplorati due approcci distinti di fusione delle feature, portando allo sviluppo di un’architettura dedicata basata sulla concatenazione dei canali.

1.1 Il fallimento della Fusione Spaziale (Spatial Concatenation)

Il primo tentativo di adattamento ha previsto una strategia di *Spatial Concatenation*. In questa configurazione, le feature map provenienti dalla backbone RGB e da quella IR sono state concatenate lungo l’asse dell’altezza (dimensione H), raddoppiando di fatto la dimensione verticale del tensore di input per l’encoder ($H_{in} \rightarrow 2H$).

L’ipotesi era che il meccanismo di attenzione deformabile potesse apprendere autonomamente le relazioni tra le due modalità. Tuttavia, l’approccio ha presentato due criticità fatali:

- **Esplosione Computazionale:** Il raddoppio delle dimensioni spaziali ha costretto a ridurre i livelli delle feature map (da 4 a 2) per evitare problemi di memoria (OOM), limitando la capacità del modello di rilevare oggetti a diverse scale.
- **Rottura Semantica:** Alterare la geometria spaziale invalida i *reference points* pre-addestrati, introducendo una discontinuità che il modello non è riuscito a compensare, portando a metriche mAP prossime allo zero.

1.2 Implementazione della Channel Concatenation con Proiezione

Per preservare l’allineamento spaziale e la capacità rappresentativa originale, è stata implementata una nuova strategia basata sulla **Channel Concatenation**, definita nel modulo `DeformableDetrFusionBackbone`.

A differenza dell’approccio precedente, questa architettura mantiene inalterate le dimensioni spaziali ($H \times W$) e opera la fusione lungo la dimensione dei canali. Il processo si articola nei seguenti step:

1. **Dual Backbone Indipendente:** Vengono istanziate due backbone parallele (ResNet-50) per estrarre le feature separatamente da RGB e IR. I pesi della backbone IR sono inizializzati adattando quelli pre-addestrati su RGB (media dei canali) per favorire la convergenza.
2. **Concatenazione e Proiezione:** Per ogni livello della piramide di feature, le feature F_{RGB} e F_{IR} vengono concatenate e proiettate:

$$F_{cat} = \text{Concat}(F_{RGB}, F_{IR}) \in \mathbb{R}^{2C \times H \times W}$$

$$F_{fused} = \text{Conv}_{1 \times 1}(F_{cat}) \in \mathbb{R}^{C \times H \times W}$$

L’uso di una convoluzione 1×1 permette di apprendere una fusione pesata mantenendo il numero di canali C compatibile con l’encoder originale.

3. **Mantenimento della Multi-Scala:** Grazie all’efficienza di questa fusione, è stato possibile mantenere attivi tutti i **4 feature levels** standard di Deformable DETR, garantendo la massima robustezza nel rilevamento di oggetti di piccole dimensioni senza incorrere in colli di bottiglia computazionali.

Questa configurazione garantisce che ogni "pixel" nelle feature map in ingresso al Transformer contenga un'informazione ibrida (RGB+IR) perfettamente allineata, permettendo al modello di sfruttare i pesi pre-addestrati di Deformable DETR senza subire disallineamenti geometrici.

Table 10: Risultati Deformable DETR (Fusion)

Testato su	Threshold	mAP@50 (Def-DETR)	mAP@50 (RT-DETR)	mAP@50 (DETR)
$D_{\text{RGBa-IRs}}$	0.01	0.291	0.357	0.417
	0.10	0.290	0.356	
D_{IRo}	0.01	0.090	0.252	0.173
D_{VISo}	0.01	0.292	0.246	-

2 Ottimizzazione di RT-DETR: Il Modulo FAM (Feature Alignment Module)

Nonostante l'efficienza di RT-DETR, l'additive fusion soffre dei disallineamenti spaziali tra i sensori RGB e Termici.

Per risolvere il problema geometrico senza appesantire il modello, è stato implementato un **Feature Alignment Module (FAM)** basato su convoluzioni deformabili. Questo modulo è inserito tra l'uscita delle backbone e la fusione additiva.

2.1 Architettura del FAM

L'idea è utilizzare la ricchezza semantica e la risoluzione superiore dell'immagine RGB per calcolare come "distorcere" la feature map termica (IR) affinché combaci perfettamente con quella RGB.

Il funzionamento, definito nella classe `FeatureAlignmentModule`, segue questi passaggi per ogni livello della piramide di feature:

1. **Offset Learning:** Le feature map RGB (F_{RGB}) e IR (F_{IR}) vengono concatenate lungo i canali. Una convoluzione standard 3×3 predice gli offset spaziali (Δp) e le maschere di modulazione (m) per ogni posizione del kernel:

$$[\Delta p, m] = \text{Conv}_{3 \times 3}(\text{Concat}(F_{\text{RGB}}, F_{\text{IR}}))$$

Il livello di output ha 27 canali (per un kernel 3×3): 18 per le coordinate (x, y) dei 9 punti di campionamento e 9 per gli scalari di modulazione (mask).

2. **Deformable Alignment:** Gli offset calcolati vengono applicati *esclusivamente* alla feature map IR tramite una Deformable Convolution (DCNv2):

$$F'_{\text{IR}}(p) = \sum_{k=1}^K w_k \cdot F_{\text{IR}}(p + p_k + \Delta p_k) \cdot m_k$$

dove p è la posizione spaziale, p_k l'offset fisso del kernel e Δp_k l'offset appreso.

3. **Fusione Additiva:** La feature map IR riallineata viene sommata a quella RGB originale:

$$F_{\text{fused}} = F_{\text{RGB}} + F'_{\text{IR}}$$

2.2 Dettagli Implementativi e Ablation Study sul FAM

Lo sviluppo del FAM non è stato lineare, i risultati più interessanti sono emersi a partire da un bug nella prima implementazione. Di seguito descrivo le cinque versioni testate, cercando di spiegare il ragionamento dietro ogni scelta.

Fase 1: Il bug della Lazy Initialization (Modello A)

La prima versione del FAM inizializzava i moduli `FeatureAlignmentModule` in modo *lazy*, cioè solo al primo `forward`. Il problema è che PyTorch registra i parametri dell’optimizer prima che il training inizi: i pesi di `offset_conv` e `deform_conv` non venivano mai visti da AdamW, che quindi non li aggiornava. In pratica, la `offset_conv` generava offset casuali e costanti, e la backbone IR riceveva in ingresso un rumore spaziale fisso e incorreggibile. L’unica cosa che il modello poteva fare per minimizzare la loss era imparare a ignorare completamente il ramo termico, il che è esattamente quello che ha fatto: la mAP IR-only è crollata a **0.0054**. Il lato positivo, inaspettato, è che forzare il modello a lavorare quasi solo sull’RGB ha prodotto un’ottima performance di fusione (**0.4286**).

Fase 2: Correzione con Eager Initialization (Modello B)

In questo modello i moduli FAM vengono istanziati nel costruttore, passando i canali corretti via `config.encoder_in_channels`. In questo modo i pesi sono registrati correttamente e l’optimizer li aggiorna fin dalla prima iterazione. Il risultato è che la robustezza IR-only è tornata a valori ragionevoli (**0.2629**), ma la fusione è calata a **0.3960**. L’ipotesi è che, potendo ora allinearsi correttamente, il modello tenda ad appoggiarsi troppo sulle feature termiche (più ”facili” per localizzare le sagome), a discapito dell’apprendimento visivo.

Fase 3: FAM congelato (Modello C)

Per capire se il beneficio del Modello A fosse legato al rumore casuale in sé o al fatto che il FAM non si aggiornasse, è stato testato un FAM con pesi congelati. In questo caso il gradiente riesce comunque a fluire all’indietro attraverso il modulo, quindi la backbone IR si adatta parzialmente, arrivando a **0.2250** in IR-only. Le performance di fusione però sono le peggiori del gruppo (**0.3857**): il rumore è costante e la rete impara a ”conviverci”, senza la spinta regolatrice del caso A.

Fase 4: Spatial Dropout (Modello D)

A questo punto l’idea era di penalizzare il ramo termico in modo controllato, introducendo uno *Spatial Dropout* al 40% prima della fusione additiva (parametro `ir_dropout_rate` nel costruttore). L’effetto sperato era costringere il modello a non fare affidamento esclusivo sull’IR, rafforzando il contributo RGB. In parte ha funzionato: la fusione è risalita a **0.3936** e il VIS-only a **0.2716**. Il limite del dropout è però che azzerava interi canali della feature map, eliminando anche informazione semantica utile (non solo geometrica), il che ha un impatto negativo sulla capacità di riconoscimento termico puro.

Fase 5: Stochastic Spatial Jitter (Modello E)

L’ultima versione formalizza l’idea emersa osservando il Modello A: invece di aggiungere rumore casuale fisso agli offset (come accadeva con il bug), viene aggiunto durante il training un rumore Gaussiano $\mathcal{N}(0, \sigma^2)$ agli offset calcolati dalla `offset_conv`. L’effetto è un tremolio spaziale controllato che rende le coordinate termiche deliberatamente inaffidabili, costringendo il modello a appoggiarsi sull’RGB per la localizzazione precisa, ma senza toccare il contenuto semantico delle feature termiche. Il risultato è il migliore in assoluto per la fusione: **0.4381**.

SSJ e Modal Dropout: perché servono entrambi

Un esperimento aggiuntivo ha applicato l’SSJ senza modal dropout, addestrando cioè il modello sempre in modalità fusione. Le performance sono calate sia in fusione (**0.3890**) che in IR-only (praticamente 0): il modello ha semplicemente smesso di usare il ramo termico, appoggiandosi interamente all’RGB. La conclusione è che l’SSJ da solo non basta: serve il modal dropout (configurazione 20% IR, 20% RGB, 60% Fusion) per obbligare la rete a mantenere funzionante anche il ramo termico, privandola periodicamente dell’RGB durante il training.

Analisi Comparativa

La Tabella 11 sintetizza i risultati di tutti i modelli testati con diverse soglie di confidenza (Thr).

Non solo l’SSJ ottiene il miglior risultato in fusion, ma evita del tutto i disastri unimodali di annullamento dell’originario bug Lazy, producendo per il solo ramo termico una map@50 di circa **0.1818**.

Table 11: Ablation Study sull’evoluzione del FAM e l’impatto dello Spatial Jitter (mAP@50).

Dataset	Thr	Modello A (Lazy Bug)	Modello B (Eager Corretto)	Modello C (Eager Freeze)	Modello D (Spatial Dropout)	Modello E (Spatial Jitter)
$D_{RGBa-IRs}$	0.01	0.4286	0.3960	0.3857	0.3936	0.4381
	0.10	0.4277	0.3944	0.3840	0.3774	0.4363
D_{IRo}	0.01	0.0054	0.2629	0.2250	0.2248	0.1818
	0.10	0.0044	0.2627	0.2206	0.2167	0.1780
D_{VISo}	0.01	0.3000	0.2620	0.2517	0.2716	0.2697
	0.10	0.2987	0.2613	0.2515	0.2674	0.2695

3 Lo Stato dell'Arte: DINO con Fusione Avanzata

Infine è stata implementata l'architettura **DINO** (DETR with Improved deNoising anchor boxes). Sebbene strutturalmente basato su Deformable DETR, DINO rappresenta l'attuale stato dell'arte grazie all'introduzione del *Contrastive Denoising Training* e della *Mixed Query Selection*, tecniche che migliorano drasticamente la velocità di convergenza e la stabilità delle predizioni.

L'implementazione introduce un meccanismo di fusione più sofisticato rispetto ai tentativi precedenti, progettato per gestire meglio la non-linearità delle relazioni tra IR ed RGB.

3.1 Enhanced Channel Fusion

Mentre nel Deformable DETR la fusione avveniva tramite una semplice proiezione lineare, per DINO è stato sviluppato un blocco di fusione non lineare all'interno della **DinoFusionBackbone**. Dopo la concatenazione delle feature lungo la dimensione dei canali (*Channel Concatenation*, $F_{cat} \in \mathbb{R}^{2C}$), le feature attraversano la seguente pipeline:

$$F_{fused} = \text{ReLU}(\text{GN}(\text{Conv}_{1 \times 1}(F_{cat})))$$

Dove:

- **Conv_{1×1}**: Riduce la dimensionalità da $2C$ a C , imparando a pesare le due modalità.
- **GN (GroupNorm)**: A differenza della Batch Normalization, la Group Normalization (impostata su 32 gruppi) garantisce stabilità statistica anche con *batch size* molto ridotti (spesso necessari dato l'elevato consumo di VRAM di DINO).
- **ReLU**: Introduce una non-linearità che permette al modello di apprendere relazioni più complesse, attivando le feature solo quando c'è una concordanza significativa o un segnale forte in una delle modalità.

3.2 Strategia di Inizializzazione e Training

Poiché le miglirie di DINO risiedono principalmente nella strategia di addestramento (Denoising) piuttosto che nella struttura del decoder, è stato possibile ereditare la classe base **DeformableDetrModel**, sostituendo esclusivamente la backbone.

Per l'inizializzazione dei pesi:

- La backbone RGB carica i pesi pre-addestrati standard (es. su COCO).
- La backbone IR viene inizializzata adattando i pesi RGB tramite la media dei canali ($W_{IR} = \frac{1}{3} \sum W_{RGB}$), fornendo un punto di partenza robusto che viene poi raffinato ("fine-tuned") durante il training.

Questa configurazione mira a unire la capacità di generalizzazione di DINO con la robustezza della fusione multimodale non lineare, cercando di superare i limiti di confidenza osservati con RT-DETR nelle scene complesse.

Viste le prestazioni superiori a RT-DETR nella modalità fusion questo farebbe pensare che implementando il Feature Alignment Module anche in DINO avremmo risultati ancora migliori di quelli ottenuti con RT-DETR.

Table 12: Risultati DINO vs RT-DETR base.

Testato su	Threshold	mAP@50 (DINO)	mAP@50 (RT-DETR Base)
$D_{\text{RGBa-IRs}}$	0.01	0.380	0.357
$D_{\text{RGBa-IRs}}$	0.10	0.377	0.356
D_{IRo}	0.01	0.166	0.252
D_{VISo}	0.01	0.226	0.246

Analisi Comparativa Finale

La campagna sperimentale condotta su diverse architetture (DETR, Deformable DETR, RT-DETR, DINO) e strategie di fusione (Additive, CMX, FAM) permette di fare un quadro chiaro delle sfide legate al rilevamento multimodale in scenari di ricerca e soccorso.

Dall’analisi dei risultati emergono quattro evidenze principali:

- **Efficienza vs. Complessità:** L’architettura **RT-DETR** si è rivelata la scelta strutturale più solida per applicazioni real-time. Rispetto a DETR originale (lento) e Deformable DETR (computazionalmente oneroso se non ottimizzato con *Channel Concatenation*), RT-DETR offre il miglior bilanciamento. I tentativi di aumentare la complessità del modulo di fusione tramite framework pesanti come CMX (Zhang et al.) sono falliti a causa dell’inerzia di addestramento su dataset di dimensioni contenute, portando a fenomeni di interferenza distruttiva.
- **Il Dilemma dell’Allineamento (FAM) e la Soluzione SSJ:** L’introduzione del **Feature Alignment Module (FAM)** ha rappresentato una svolta prestazionale, portando RT-DETR a superare agilmente il modello base (0.357). Inizialmente ciò ha introdotto una forte dipendenza dalla modalità guida, al punto da far crollare la robustezza in *single-modality* (IR-only a 0.005 mAP). Tuttavia, **l’introduzione dello Stochastic Spatial Jitter (SSJ)** ha risolto definitivamente questo dilemma: regolarizzando spazialmente le feature, si è ristabilita un’ottima indipendenza dell’IR (0.181 mAP) spingendo al contempo le prestazioni di fusione al nuovo picco di **0.438 mAP**, con velocità di inferenza real-time.
- **Evoluzione Architetture (DINO):** L’implementazione di **DINO** ha dimostrato che è possibile migliorare le prestazioni (0.380 mAP) rispetto a RT-DETR grazie alle tecniche di *denoising*, suggerendo che l’architettura Transformer ha ancora margine di miglioramento se supportata da strategie di training moderne.
- **Strategia di Input:** Il modello addestrato su immagini integrali (640×640) ha surclassato costantemente la strategia di *Tiling*. La perdita di contesto globale e la ridotta frequenza di campionamento dei soggetti nei ritagli hanno reso il tiling inefficace, confermando che la sfida principale per questo task è data dal disallineamento geometrico dei sensori e non dalle piccole dimensioni dei soggetti.

Conclusioni e Prospettive Future

Alla luce dei risultati ottenuti possiamo evidenziare due soluzioni ottimali in base ai vincoli operativi:

1. **Robustezza Operativa Estrema:** Se la priorità vitale è garantire il rilevamento anche in caso di oscuramento o malfunzionamento critico del sensore visivo (es. fumo denso o buio totale), l’architettura **RT-DETR con Additive Feature Fusion pura o Late Fusion** rappresenta la scelta più invariante. Garantisce prestazioni solide e bilanciate sia

in modalità combinata che singola, pur perdendo i picchi di precisione geometrica offerti dai moduli di allineamento.

2. **Massima Precisione Multimodale:** L'architettura **RT-DETR + FAM + SSJ (Stochastic Spatial Jitter)** rappresenta allo stato attuale la configurazione definitiva. La capacità del modulo FAM di correggere i disallineamenti sfruttando la risoluzione RGB, unita alla regolarizzazione del Jitter stocastico, permette di massimizzare il punteggio mAP portandolo al record di **0.438**, senza sacrificare la stabilità operativa in fase addestrativa.

Sviluppi Futuri:

La naturale evoluzione di questo lavoro prevede la trasposizione delle metodologie vincenti sull'architettura DINO. Dato che il DINO nativo ha mostrato una base di partenza superiore a RT-DETR (0.380 vs 0.357), l'integrazione del modulo FAM e dello Spatial Jitter potrebbe alzare ulteriormente l'asticella dello State-of-the-Art, puntando a superare stabilmente la barriera dello 0.45 mAP. Parallelamente, per estremizzare ulteriormente la robustezza ai guasti senza ricorrere ad architetture a doppio detector parallelo (*Late Fusion* con raddoppio computazionale), la strada più promettente è lo sviluppo di un meccanismo di **Adaptive Gating**: un modulo capace di modulare o disattivare dinamicamente l'allineamento FAM quando la confidenza semantica del sensore visibile scende sotto una soglia critica, fondendo così l'assoluta precisione geometrica dell'SSJ con un'infallibile robustezza unimodale in tempo reale.